PBBI ekstraksi klausa — rencana training v0.1.4 (final)

Status: disetujui, belum dijalankan · **Tanggal:** 1 November 2026 **Keputusan:** pakai **Approach 2** (pemilihan data berdasarkan cluster struktur PDF) dan **struktur train/eval/test** di bawah. **Dokumen pendamping:** `pbbi-v0.1.4-summary.md` dan `pbbi-v0.1.4-summary.pdf` (analisis lengkap: kenapa kalah, isu, perbandingan kedua approach).

1. Ringkasan keputusan

Hal	Keputusan
Approach	**Approach 2: cluster struktur PDF**, 6 cluster (A daftar datar, B induk → anak, C naratif, D tabel/kolom, E dwibahasa, F desimal)
Sumber eval dan test	**Hanya dari 60 dokumen awal** (label pengawas BI)
Dokumen baru dari `/all`	**Hanya masuk train**
Syarat coverage	Eval dan test masing-masing punya **minimal 1 dokumen per cluster** (struktur maupun produk), dengan dua pengecualian yang tidak mungkin dipenuhi (bagian 3.4)
Keluaran	**Murni dari model**: tidak ada pasca-proses atau logika aplikasi. Perbaikan hanya lewat data, cara training, dan system prompt (bila disetujui)
PERMATA IB	Dianggap bisa diunggah (deteksi bahasa aplikasi diperbaiki atau tersedia versi PDF yang benar)
Komposisi	**Rekomendasi: 58 train / 9 eval / 18 test.** Maksimal: 66 / 9 / 18

2. Aturan yang dipegang

1. 60 dokumen `preparation/raw` tetap dipakai semuanya, dengan versi `raw` sebagai acuan bila berbeda dengan `/all`.
2. Eval dan test hanya dari 60 dokumen itu.
3. 17 dokumen test lama dipertahankan, supaya skor v0.1.4 sebanding dengan v0.1.2 dan v0.1.3.
4. Satu PDF yang sama tidak boleh berada di dua split. Karena itu CIMB IB (satu PDF dengan CIMB KD di eval) dan SINARMAS MB (satu PDF dengan SINARMAS UE di test) tidak dipakai.
5. Metrik: Jaccard rata-rata tanpa ambang (recall, precision, F1), dihitung dari keluaran model apa adanya.

3. Struktur split final

Pembagian 60 dokumen awal: **33 train · 9 eval · 18 test.**

3.1 Test (18)

Dokumen	Cluster	Produk	Catatan
BCA KD	A	Kartu Debit	test lama
BRI UE Chip	A	UE Chip-Based	test lama
DBS MB	A	Mobile Banking	test lama
JATENG KD	A	Kartu Debit	test lama
MUAMALAT IB	A	Internet Banking	test lama
SINARMAS UE Server	A	UE Server-Based	test lama
SMBC KK	A	Kartu Kredit	test lama
SULTRA KD	A	Kartu Debit	test lama
BJB MB	B	Mobile Banking	test lama
MANDIRI MB	B	Mobile Banking	test lama
OCBC IB	B	Internet Banking	test lama
NAGARI MB	C	Mobile Banking	test lama

Dokumen	Cluster	Produk	Catatan
OCBC KK	C	Kartu Kredit	test lama
OY PG	C	Payment Gateway	test lama
SHOPEEPAY UE Server	C	UE Server-Based	test lama
BOC MB&IB	E	MB & IB	test lama
SEABANK MB	F	Mobile Banking	test lama
KALSEL KD	**D**	Kartu Debit	**test tambahan, pindah dari train**

KALSEL KD masuk karena cluster D tidak punya dokumen test. Dari 3 dokumen D di 60 dokumen, UOB KK dipakai untuk eval dan BSI MB dipertahankan di train karena punya 8 contoh kalimat pembuka definisi. KALSEL KD pernah dipakai melatih v0.1.3, jadi skornya **dilaporkan terpisah** dan hanya dibandingkan dengan gpt-4.1-mini.

3.2 Eval (9)

Dokumen	Cluster	Produk	Penyelenggara	Catatan
CIMB KD	A	Kartu Debit	Swasta nasional	eval lama
JAMBI KD	A	Kartu Debit	BPD	eval lama (label perlu dicek dengan Legal)
BNI MB	B	Mobile Banking	BUMN	eval lama
OVO	B	UE Server-Based	LSB	eval lama
MANDIRI UE Chip	B	**UE Chip-Based**	BUMN	pindah dari train
MAYBANK MB&IB	**C**	**MB & IB**	**Multinasional**	pindah dari train
UOB KK	**D**	**Kartu Kredit**	Multinasional	pindah dari train
STANCHART IB	**E**	**Internet Banking**	Multinasional	pindah dari train
MEGA KK	**F**	Kartu Kredit	Swasta nasional	pindah dari train

Kelima dokumen yang dipindah dipilih supaya satu dokumen menutup lebih dari satu celah coverage. Yang **sengaja tidak dipindah** adalah dokumen yang menjadi sumber contoh langka di train: - BSI MB, ACEH MB, SMBC IB, YUKK: contoh kalimat pembuka definisi; - STANCHART KK: 14 contoh tabel; - UOB MB: dokumen terpanjang.

3.3 Train dari 60 dokumen (33)

Cluster	Dokumen
A (16)	BANTEN KD, BCA IB, BCA MB, BNI KK, CIMB UE Server, JATENG MB, JATIM KD, JATIM MB, JTRUST MB&IB, KALTIMTARA MB&IB, MEGA MB, NTT IB, OCBC KD, SINARMAS KD, SMBC IB, UOB IB
B (7)	ACEH MB, BANTEN MB, DANAMON UE Chip, GOPAY UE Server, JAGO MB, MANDIRI KD, SULSELBAR KD
C (2)	MASPION IB, MASPION KD
D (1)	BSI MB
E (2)	CIMB KK, STANCHART KK
F (5)	BTN IB, HONEST KK, UOB MB, WISE Remitansi, YUKK PG

3.4 Cek syarat "minimal 1 dokumen per cluster"

Pengelompokan	Eval (9)	Test (18)
Struktur A · B · C · D · E · F	2 · 3 · 1 · 1 · 1 · 1 ✔	8 · 3 · 4 · 1 · 1 · 1 ✔
IB · KK · KD · MB · MB&IB	1 · 2 · 2 · 1 · 1 ✔	2 · 2 · 4 · 5 · 1 ✔
UE Chip · UE Server	1 · 1 ✔	1 · 2 ✔
Payment Gateway	✘ (pengecualian)	1 ✔
Remitansi	✘ (pengecualian)	✘ (pengecualian)
Swasta · BPD · BUMN · Multinasional · LSB	2 · 1 · 2 · 3 · 1 ✔	✔ semua

Pengecualian yang tidak mungkin dipenuhi: - **Remitansi** hanya 1 dokumen di 60 (WISE). Tidak bisa ada di eval dan test sekaligus, jadi WISE tetap di train. - **Payment Gateway** hanya 2 dokumen (OY di test, YUKK di train). Memindahkan YUKK ke eval membuat train tidak punya Payment Gateway dan kehilangan 15 contoh kalimat pembuka definisi. YUKK tetap di train.

3.5 Train dari dokumen baru `/all`

Semua dokumen baru hanya masuk train. Urutan pengerjaan oleh pengawas mengikuti prioritas.

Prioritas 1 (12 dokumen): menyasar sub-butir yang digabung, dokumen panjang, dan kalimat pembuka definisi

Dokumen	Cluster	Produk	Token	Baris `a.`	Alasan
JAKARTA Mobile Banking	B	MB	21.147	234	Sub-butir terbanyak, panjang, cluster terlemah
STANCHART Kartu Debit	F	KD	13.067	157	Sub-butir; Multinational; F menggabungkan 78 dari 100 anak berhuruf
CIMB Mobile Banking	A	MB	20.925	125	Panjang dengan banyak sub-butir
DANA	C	UE Server	25.446	53	Panjang; cluster C; UE Server
DBS Kartu Kredit	C	KK	16.734	0	Kalimat pembuka definisi; Multinational
PERMATA Internet Banking	C	IB	≈ 12–13k*	1	Kalimat pembuka definisi; IB baru terbesar; cluster C (train hanya 2 dari 60)
DANAMON Kartu Debit	A	KD	9.816	52	Kalimat pembuka definisi dan sub-butir
LINKAJA	C	UE Server	11.768	32	Cluster C; UE Server
NOBU Mobile Banking	A	MB	20.332	47	Panjang
NOBU Kartu Kredit	A	KK	10.668	38	KK dengan sub-butir
NTB Mobile Banking	B	MB	2.473	33	Cluster B
BCA UE Server-Based	B	UE Server	3.888	24	Cluster B; UE Server

*Token PERMATA IB adalah perkiraan, karena teks utuhnya belum bisa diambil lewat pipa aplikasi.

Cluster PERMATA IB = C (naratif). Dokumen ini dibagi per "Pasal 1" sampai "Pasal 20", dan isi setiap pasal berupa paragraf tanpa nomor: tidak ada daftar `1.`, hanya 1 sub-butir `a.`, dan tidak ada nomor desimal. Clustering yang sama (102 PDF, Ward, 6 cluster) dihitung ulang setelah header/footer browser dibuang dan baris kolom sempit disambung kembali menjadi paragraf. Hasilnya, jarak ke pusat cluster C 1,15, sedangkan cluster terdekat berikutnya (A) 3,42. Pada teks yang rusak oleh filter bahasa, dokumen ini sempat terbaca sebagai E (dwibahasa); itu artefak filter, bukan bentuk dokumennya.

Prioritas 2 (13 dokumen): menutup celah coverage

Dokumen	Cluster	Alasan
KEPRI MB, MALUT KD, SUMUT KD, SULUTGO KD, JOGJA KD	D	Tabel dan kolom; D tinggal 1 dokumen di train setelah UOB KK ke eval dan KALSEL KD ke test
BCA KK	C	Naratif; Kartu Kredit
BALI KD, NTT MB	B	Cluster B
DANAMON General	A	Jenis General pertama; kalimat pembuka definisi; panjang
SMBC MB	A	Panjang
SINARMAS IB, SINARMAS KK, BSI KK	A	Internet Banking dan Kartu Kredit

Prioritas 3 (8 dokumen, opsional, untuk komposisi maksimal): BRI KD, JAMBI MB, BJB Syariah MB, SULSELBAR MB, SUMSELBABEL MB, SUMUT MB, PERMATA MB, MEGA UE. Semuanya cluster A, pendek, dan produknya sudah kuat.

Tidak dipakai (11 dokumen baru): - BJB Syariah KD, DANAMON KK: scan; - HSBC KK: gambar; - BOC KD ENG, BOC KK ENG, PERMATA KK ENG: berbahasa Inggris, ditolak aplikasi; - HSBC General, STANCHART General: terlalu panjang; - DANAMON MB: mendekati batas token; - BALI MB: dwibahasa, teks rusak oleh filter; - JAMBI MB versi unclean: duplikat.

3.6 Komposisi akhir

	Train	Eval	Test	Total
v0.1.3 (sekarang)	39	4	17	60
v0.1.4 rekomendasi (P1 + P2)	**58** = 33 + 25 baru	**9**	**18**	**85**
v0.1.4 maksimal (P1 + P2 + P3)	66 = 33 + 33 baru	9	18	93

4. Coverage train sebelum dan sesudah

Per cluster struktur

Cluster	v0.1.3	v0.1.4 rekomendasi	v0.1.4 maksimal
A. Daftar datar	16	25	33
B. Induk → anak	8	12	12
C. Naratif	3	7	7
D. Tabel/kolom	3	6	6
E. Dwibahasa	3	2	2
F. Desimal	6	6	6
Total	**39**	**58**	**66**

Per produk

Produk	v0.1.3	v0.1.4 rekomendasi	v0.1.4 maksimal
Internet Banking	7	8	8
Kartu Kredit	6	9	9
Kartu Debit	8	14	15
Uang Elektronik (Chip + Server)	4	6	7
Mobile Banking	9	16	22
MB & IB	3	2	2
General	0	1	1
Payment Gateway	1	1	1
Remitansi	1	1	1
Total	**39**	**58**	**66**

Ciri penting

Ciri di train	v0.1.3	v0.1.4 rekomendasi
Dokumen dengan teks ≥ 20k token	2	7
Dokumen dengan kalimat pembuka definisi	4	8
Multinational	8	7 (3 pindah ke eval, +2 baru)
Baris sub-butir berhuruf di teks dokumen baru	–	+1.066

Konsekuensi yang diterima: cluster E (dwibahasa) di train turun dari 3 menjadi 2, dan tidak ada dokumen dwibahasa baru yang bersih. MB & IB di train turun dari 3 menjadi 2.

---

5. Cara memperbaiki model (tanpa logika aplikasi)

Penyebab kekalahan v0.1.3	Perbaikan dari sisi model
Sub-butir digabung (22,5–24,2 dari 29,2 poin recall hilang; 55–61% anak berhuruf digabung)	Dokumen prioritas 1 dengan banyak sub-butir dan dokumen panjang; opsi oversampling; opsi baris jendela
Nomor urut tersalin (JATENG, SULTRA, BRI)	Panduan label konsisten (item mandiri tanpa nomor); kalimat di system prompt bila disetujui
Kalimat pembuka definisi tidak diulang (OCBC IB)	Contoh di train naik dari 4 menjadi 8 dokumen; contoh di system prompt bila disetujui
Tabel dipecah (BRI)	Dokumen bertabel di luar Kartu Kredit (KEPRI, MALUT, SUMUT, SULUTGO, JOGJA)

Opsi cara training (perlu diputuskan sebelum build): - **Oversampling:** baris dokumen yang kaya sub-butir (JAKARTA MB, STANCHART KD, CIMB MB, DANAMON General) diulang 2–3 kali di train. - **Baris jendela:** turunkan batas baris di `build.py` agar dokumen panjang dipecah menjadi beberapa baris berisi bagian utuh. Fitur ini sudah ada; efeknya belum diuji. - **System prompt:** tambah kalimat "item bernomor yang berdiri sendiri ditulis tanpa nomornya" dan satu contoh kalimat pembuka definisi. Perlu persetujuan, dan semua baris dibangun ulang dengan prompt baru.

Konfigurasi training lain mengikuti v0.1.3 (LoRA r 16, lr 5e-5), dengan **1 epoch** karena v0.1.2 dan v0.1.3 sama-sama memilih step 20 (sekitar 1 epoch). Eval 9 dokumen dipakai untuk konfirmasi pilihan checkpoint.

6. Prediksi skor (17 dokumen test lama)

Skenario	Train	Recall	Precision	F1
v0.1.3 (terukur)	39	70,8	84,4	77,0
Pesimis: rekomendasi, model belajar sedikit	58	~72,7	~84,0	~77,9
Realistis: rekomendasi	58	**~74,5**	**~83,6**	**~78,8**
Realistis: maksimal + oversampling + prompt	66	**~76,5**	**~83,4**	**~79,8**
Optimis: maksimal, model memecah sub-butir dengan baik	66	~79,8	~82,9	~81,3
Batas atas (model menulis persis seperti label)	–	83,2	81,8	82,5

Metrik	Kemungkinan mencapai ≥ 80%
Precision	**Tercapai di semua skenario**
F1	**Di ambang batas.** Realistis maksimal sekitar 79,8%; melewati 80% hanya di skenario optimis.
Recall	**Kemungkinan besar belum di v0.1.4.** Skenario optimis pun sekitar 79,8%.

Cara menghitung: - Titik awal adalah skor v0.1.3. - Batas atas adalah simulasi seandainya model sendiri tidak menyalin nomor, memecah sub-butir, dan mengulang kalimat pembuka seperti label. Ini bukan aturan aplikasi. - Seberapa jauh model bergerak ke batas atas diturunkan dari satu-satunya data historis: dari v0.1.2 ke v0.1.3, +8 dokumen menggerakkan sekitar 11% dari jarak itu. - Rekomendasi (+19 dokumen bersih) diasumsikan bergerak sekitar 30%, maksimal dengan oversampling dan prompt sekitar 45%, dan skenario optimis sekitar 70%. - **Ketidakpastiannya besar.** Dasarnya hanya satu langkah historis, dan efek oversampling, baris jendela, serta prompt belum pernah diukur.

7. Langkah kerja

1. **Pipa teks:** perbaiki deteksi bahasa aplikasi untuk PDF cetak browser berkolom sempit, atau dapatkan PDF PERMATA IB yang bisa diunggah.
2. **System prompt:** putuskan dua kalimat tambahan (nomor item mandiri; contoh kalimat pembuka definisi).
3. **Panduan label untuk pengawas:** anak berhuruf dipisah dengan teks induk, item mandiri tanpa nomor, kalimat pembuka definisi diulang, satu tabel satu klausa.
4. **Ekstraksi pengawas:** prioritas 1 (12), lalu prioritas 2 (13). Prioritas 3 (8) bila waktu tersedia.
5. **Susun split** sesuai bagian 3: pindahkan KALSEL KD ke test, dan MANDIRI UE Chip, MAYBANK MB&IB, UOB KK, STANCHART IB, MEGA KK ke eval.
6. **Build data** dengan `build.py`; cek token semua baris (≤ 98.304) dan panjang jawaban (≤ 65.536); putuskan oversampling dan baris jendela.
7. **Training v0.1.4**, 1 epoch.
8. **Evaluasi** keluaran model apa adanya, dibandingkan gpt-4.1-mini per dokumen: - 17 test lama (sebanding dengan v0.1.2 dan v0.1.3); - KALSEL KD terpisah; - per cluster struktur dan per produk.

Gerbang rilis: - F1 pada 17 test lama tidak di bawah v0.1.3 (77,0). - Tidak ada dokumen yang turun lebih dari 0,03. - Jumlah dokumen yang kalah dari gpt tidak bertambah.

Recall, precision, dan F1 dilaporkan apa adanya, termasuk bila belum mencapai 80%.

Bila recall masih di bawah 80% setelah v0.1.4: langkah berikutnya adalah ekstraksi pengawas untuk dokumen tambahan dengan banyak sub-butir berhuruf, karena 33 dokumen baru yang tersedia sudah terpakai. Mengubah isi test bukan jalan keluarnya, karena itu hanya mengubah cara mengukur.

8. Risiko

Risiko	Dampak	Mitigasi
Model belajar memecah sub-butir lebih sedikit dari perkiraan	Recall dan F1 di bawah 80%	Oversampling, baris jendela, dan prompt; putaran data berikutnya

Risiko	Dampak	Mitigasi
Train dari dokumen terverifikasi berkurang 6	Contoh berkualitas tinggi berkurang	Diimbangi 25–33 dokumen baru; dokumen sumber contoh langka tetap di train
Cluster E di train hanya 2	Dokumen dwibahasa tetap lemah (BOC 0,558)	Catat sebagai keterbatasan
Label baru tidak konsisten	Model belajar pola bertentangan	Panduan label tertulis sebelum ekstraksi
PERMATA IB belum bisa diunggah	Prioritas 1 berkurang satu	Komposisi tetap berjalan tanpa dokumen ini (57 / 9 / 18)
Label JAMBI KD (eval) bermasalah	Sinyal eval berisik	Cek dengan Legal; eval kini 9 dokumen, sehingga satu dokumen tidak dominan
Test kecil (17 + 1)	Skor per dokumen berisik	Gerbang per dokumen; laporan per dokumen

9. Pertanyaan terbuka

1. Apakah dua kalimat tambahan di system prompt disetujui?
2. Kapan PERMATA IB tersedia dalam versi yang bisa diunggah?
3. Apakah oversampling dan baris jendela dipakai di v0.1.4?
4. Berapa dokumen yang sanggup diekstrak pengawas: prioritas 1 saja, 1 dan 2 (rekomendasi), atau semua (maksimal)?
5. Apakah label JAMBI KD perlu dikoreksi oleh Legal sebelum dipakai sebagai eval?

Lampiran — sumber angka

- Skor dan dekomposisi kesalahan: `preparation/data/scores/test-{v0.1.2,v0.1.3,gpt-4.1-mini}-t0`, diparse dengan `parse_reply` dan `finalize` aplikasi; Jaccard rata-rata dengan pasangan satu lawan satu.
- Cluster: Ward, 6 cluster, 8 fitur struktur dari teks `pdftotext -layout`; untuk 60 dokumen dihitung dari teks versi `raw`.
- Produk, penyelenggara, dan split: `preparation/data/build-report.json`.
- Token: tokenizer `scalejade/qwen-sea-lion-v4.5-27b-pbbi` revisi `8d32a4b9`.
- Batas: `max_seq_length` 98.304 (`training/configs/pbbi-extraction.yaml`); output aplikasi 65.536 (`preparation/app_request.py`).
- Rincian analisis: `pbbi-v0.1.4-summary.md`.